

UNIVERZITA KOMENSKÉHO V BRATISLAVE  
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY

NÁZOV VAŠEJ BAKALÁRSKEJ PRÁCE  
BAKALÁRSKA PRÁCA

2024

MENO PRIEZVISKO, PRÍP. TITULY



UNIVERZITA KOMENSKÉHO V BRATISLAVE  
FAKULTA MATEMATIKY, FYZIKY A INFORMATIKY

NÁZOV VAŠEJ BAKALÁRSKEJ PRÁCE  
BAKALÁRSKA PRÁCA

Študijný program: Informatika  
Študijný odbor: Informatika  
Školiace pracovisko: Katedra aplikovanej informatiky  
Školiteľ: tit. Meno Priezvisko, tit.

Bratislava, 2024  
Meno Priezvisko, príp. tituly





Univerzita Komenského v Bratislave  
Fakulta matematiky, fyziky a informatiky

## ZADANIE ZÁVEREČNEJ PRÁCE

**Meno a priezvisko študenta:** Michal Jaroš  
**Študijný program:** aplikovaná informatika (Jednoodborové štúdium, bakalársky I. st., denná forma)  
**Študijný odbor:** informatika  
**Typ záverečnej práce:** bakalárska  
**Jazyk záverečnej práce:** slovenský  
**Sekundárny jazyk:** anglický

**Názov:** Klasifikácia množenia tekutiny v kĺbnej dutine kolena na MR vyšetrení  
*Classification of knee effusion on MRI examination*

**Anotácia:** Táto práca sa zameriava na analýzu snímok magnetickej rezonancie kolena (MRI). Skúma techniky spracovania obrazu a metódy strojového učenia s cieľom zvýšiť diagnostickú presnosť a pomôcť zdravotníckym pracovníkom pri hodnotení porúch kolenného kĺbu.

**Cieľ:** V prvom kroku odstrániť časti skenu obsahujúce Bakerovu cystu. Následne klasifikovať množenie tekutiny v kĺbnej dutine kolena na MR vyšetrení metódami hlbokého učenia. Navrhnutú metódu otestovať a vyhodnotiť výsledky.

**Vedúci:** doc. RNDr. Zuzana Černeková, PhD.  
**Konzultant:** MUDr. Peter Bluska  
**Katedra:** FMFI.KAI - Katedra aplikovanej informatiky  
**Vedúci katedry:** doc. RNDr. Tatiana Jajcayová, PhD.  
**Dátum zadania:** 19.02.2025

**Dátum schválenia:** 29.09.2025

doc. RNDr. Damas Gruska, PhD.  
garant študijného programu

.....  
študent

.....  
vedúci práce

**Pod'akovanie:** Tu môžete poďakovať školiteľovi, prípadne ďalším osobám, ktoré vám s prácou nejako pomohli, poradili, poskytli dáta a podobne.

# Abstrakt

Slovenský abstrakt v rozsahu 100-500 slov, jeden odstavec. Abstrakt stručne sumarizuje výsledky práce. Mal by byť pochopiteľný pre bežného informatika. Nemal by teda využívať skratky, termíny alebo označenie zavedené v práci, okrem tých, ktoré sú všeobecne známe.

**Kľúčové slová:** jedno, druhé, tretie (prípadne štvrté, piate)

# Abstract

Abstract in the English language (translation of the abstract in the Slovak language).

**Keywords:**



# Obsah

|                                                                     |           |
|---------------------------------------------------------------------|-----------|
| <b>Úvod</b>                                                         | <b>1</b>  |
| <b>1 Teoretické pozadie</b>                                         | <b>3</b>  |
| 1.1 Kolená z pohľadu anatómie . . . . .                             | 3         |
| 1.2 Voda v kolene . . . . .                                         | 3         |
| 1.3 Magnetická rezonancia . . . . .                                 | 4         |
| 1.4 Konvolučné neurónové siete? . . . . .                           | 4         |
| <b>2 Súvisiace vedecké práce</b>                                    | <b>5</b>  |
| 2.1 Klasifikácia vody v kolene . . . . .                            | 5         |
| 2.2 Regresia pri kontinuálnych medicínskych ukazovateľoch . . . . . | 5         |
| 2.3 Hlboké učenie s nepresnými anotáciami . . . . .                 | 6         |
| <b>3 Dáta</b>                                                       | <b>7</b>  |
| 3.1 Formát dát . . . . .                                            | 7         |
| 3.2 Anotácie, ich interpretácia a distribúcia . . . . .             | 7         |
| 3.3 Problém s otočením . . . . .                                    | 8         |
| <b>4 Implementácia</b>                                              | <b>9</b>  |
| 4.1 Preprocessing . . . . .                                         | 9         |
| 4.2 Tréning . . . . .                                               | 9         |
| 4.3 Problémy . . . . .                                              | 9         |
| <b>5 Improvements</b>                                               | <b>11</b> |
| 5.1 Ordinal Regression . . . . .                                    | 11        |
| 5.2 Dataset cleanup . . . . .                                       | 11        |
| 5.2.1 Použitie intenzít . . . . .                                   | 11        |
| 5.2.2 Detekcia outlierov pomocou modelu . . . . .                   | 11        |
| 5.3 Label smoothing . . . . .                                       | 11        |
| <b>6 Jadro a členenie práce</b>                                     | <b>13</b> |
| 6.1 Jadro práce podľa smernice . . . . .                            | 13        |

|          |                                            |           |
|----------|--------------------------------------------|-----------|
| 6.1.1    | Súčasný stav . . . . .                     | 14        |
| 6.1.2    | Cieľ práce . . . . .                       | 14        |
| 6.1.3    | Metodika práce a metódy skúmania . . . . . | 14        |
| 6.1.4    | Výsledky práce a diskusia . . . . .        | 14        |
| <b>7</b> | <b>LaTeX</b>                               | <b>15</b> |
| 7.1      | Obrázky . . . . .                          | 15        |
|          | <b>Záver</b>                               | <b>17</b> |
|          | <b>Príloha A</b>                           | <b>21</b> |
|          | <b>Príloha B</b>                           | <b>23</b> |

# Zoznam obrázkov

|     |                                                                                                                                                 |    |
|-----|-------------------------------------------------------------------------------------------------------------------------------------------------|----|
| 1.1 | Anatomicky popísane koleno. . . . .                                                                                                             | 3  |
| 1.2 | Základné roviny zobrazenia pri magnetickej rezonancii. . . . .                                                                                  | 4  |
| 3.1 | Distribúcia anotácií podľa závažnosti zmnoženia vody v kolene. Počty tried: none – 425, minimal – 247, mild – 589, moderate – 467, severe – 96. | 8  |
| 3.2 | Porovnanie snímky kolena so správnym a nesprávnym smerovaním. . .                                                                               | 8  |
| 7.1 | Ukážka hry Červík . . . . .                                                                                                                     | 16 |



# Zoznam tabuliek

|     |                                                                  |    |
|-----|------------------------------------------------------------------|----|
| 3.1 | Počet vzoriek pre jednotlivé triedy anotácií. . . . .            | 8  |
| 7.1 | Doba výpočtu a operačná pamäť potrebná na spracovanie vstupu XYZ | 16 |



# Úvod

Cieľom tejto práce je poskytnúť študentom posledného ročníka bakalárskeho štúdia informatiky kostru práce v systéme LaTeX a ukážku užitočných príkazov, ktoré pri písaní práce môžu potrebovať. Začneme stručnou charakteristikou úvodu práce podľa smernice o záverečných prácach [10], ktorú uvádzame ako doslovný citát.

Úvod je prvou komplexnou informáciou o práci, jej cieľi, obsahu a štruktúre. Úvod sa vzťahuje na spracovanú tému konkrétne, obsahuje stručný a výstižný opis problematiky, charakterizuje stav poznania alebo praxe v oblasti, ktorá je predmetom školského diela a oboznamuje s významom, cieľmi a zámermi školského diela. Autor v úvode zdôrazňuje, prečo je práca dôležitá a prečo sa rozhodol spracovať danú tému. Úvod ako názov kapitoly sa nečísluje a jeho rozsah je spravidla 1 až 2 strany.

V nasledujúcej kapitole nájdete ukážku členenia kapitoly na menšie časti a v kapitole 7 nájdete príkazy na prácu s tabuľkami, obrázkami a matematickými výrazmi. V závere textu sa budeme venovať záležitostiam záveru bakalárskych prác.






# Kapitola 1

## Teoretické pozadie

### 1.1 Koleno z pohľadu anatómie

Koleno je najväčší kĺb v ľudskom tele, ktorý zabezpečuje spoj medzi stehennou kosťou (femur) a holennou kosťou (tibia). Zabezpečuje pohyb dolnej končatiny a teda je kritický pre správnu mobilitu - státie, chôdzu alebo beh. Skladá sa z troch kostí. Stehenná kosť, ktorá je zároveň najväčšou kosťou v tele, sa spája s holennou kosťou prostredníctvom kĺbového puzdra a väzivového aparátu. Na prednej strane kolena sa nachádza jabĺčko, ktoré sa pri ohýbaní kolena hladko posúva v drážke stehennej kosti, nazývanej sulcus femoris. Anatomicky popísane koleno je na obrázku 1.1.



Obr. 1.1: Anatomicky popísane koleno.


### 1.2 Voda v kolene

V kolennom kĺbe sa hromadí prebytočná synoviálna tekutina, čo spôsobuje opuch a potenciálne bolesti. Táto tekutina slúži na mazanie a tlmenie v kĺbe, ale pri poško-

dení kolena sa môže hromadiť nadmerne. Na MR sa zobrazuje ako čierna alebo tmavá tekutina. DOPIŠAT INFO, TAKTIEZ PRIDAT ROZDIEL MEDZI BAKEROVOU CISTOU A VODOU V KOLENNOM KLBE

### 1.3 Magnetická rezonancia

Zobrazovanie magnetickou rezonanciou (MR) je nukleárny druh zobrazovania. Narozdiel od počítačovej tomografie alebo vyšetrenia röntgenovým žiarením, MR nepoužíva ionizujúce žiarenie. Pacient je vložený do veľmi silného homogénneho poľa, do jeho tela je následne vyslaný krátky riádiofrekvenčný impulz. Po jeho skončení, sa zachytáva signál, ktorý vysielajú jadrá atómov v tele pacienta. Tento signál je použitý na skonštruovanie ob-razu. Výsledný obraz dobre zobrazuje mäkké tkanivá a je v troch základných rovinách (ilustrované na obrázku 1.2). PRIDAT NEURON RESTING TIMES, ABY SME VEDELI SPECIFIKOVAT KTORY POZIVAME MY



Obr. 1.2: Základné roviny zobrazovania pri magnetickej rezonancii.

### 1.4 Konvolučné neurónové siete?

# Kapitola 2

## Súvisiace vedecké práce

Veľká časť mojej práce sa venovala analýze článkov a štúdií, ktoré sa zaoberali klasifikáciou vody v kolene na MR snímkach a technikám pre zlepšenie tréningu na dátach s nejednoznačnými alebo nedokonalými anotáciami.

### 2.1 Klasifikácia vody v kolene

V článku [8] autori vytvorili hlbokú neurónovú sieť na binárnu klasifikáciu výskytu vody v kolene. Model bol trénovaný na sagitálnych TSE snímkach 1 628 kolien z OAI datasetu s štandardizovanými anotáciami MOAKS-ES. Na testovacej množine dosiahli accuracy len okolo 62%, čo je podľa autorov blízke výkonom rádiológa pri rovnakom probléme.

Článok [12] skúma rôzne architektúry na binárnu klasifikáciu vody v kolene na základe X-ray snímkov. Trénované boli hlboké neurónové siete na 1413 snímkach. Autori použili v preprocessingu detekciu patelly s YOLOv8 sieťou, na základe ktorej štandardizovali veľkosť a zoom. Najviac sa im osvedčila architektúra DenseNet121, s ktorou dosiahli accuracy 0,803 percent a ktorú sme použili aj v našom návrhu.

### 2.2 Regresia pri kontinuálnych medicínskych ukazovateľoch

Autori v článku [6] skúmajú použitie regresie pri hlbokom učení na diagnózach, ktoré su kontinuálneho charakteru. Došli k záveru, že priama regresia často krát ponúka lepšie predikcie, interpretabilitu a viacej informácii ako transformácia anotácií do binárnych tried.

## 2.3 Hlboké učenie s nepresnými anotáciami

Ďalší článok [5] skúma hlboké učenie s anotáciami, ktoré sú nepresné alebo neúplné. Systematicky analyzuje prístupy na prácu s takýmito dátami a delí ich do kategórií ako: čistenie dát, robustné architektúry, robustné loss funkcie a preváhovanie dát. Experimenty robili na detekcii a segmentácii mozgových lézií, klasifikácii prostaty a segmentácii mozgu. Zistili, že najväčší prínos má korekcia alebo filtrácia zlých anotácií, ktoré výrazne zlepšilo F1 skóre a Dice koeficient oproti baseline modelom. Použitie robustných loss funkcií prinieslo lepšie výsledky najmä pri klasifikačných a detekčných problémoch.

Článok [11] sa taktiež zaoberá anotačným šumom, pričom sa zameriava hlavne na detekciu podozrivých anotácií cez vysokú stratu, vysokú neistotu modelu alebo veľký rozdiel vo feature space. Okrem toho opisuje aj robustné loss funkcie a úpravy architektúr. Práca upozorňuje, že vysoká strata nemusí znamenať chybný label, ale môže ísť o hard to decide snímok, a preto je nerozumné slepé odstránovanie dát z datasetu. Práca odporúča kombináciu robustných metód ako zmenu loss alebo reweighing s použitím korektného validačného a testovacieho setu.

V článku [9] autori prezentujú prehľad techník hlbokého učenia na dátach s chybnými označeniami. Opisujú vznik týchto chýb v medicínskych dátach a to hlavne kvôli komplexnosti anatómie, rozdielnym vnímaním anotácií rôznymi expertmi a obmedzením zdrojov. Poukazujú na výrazne zníženie generalizačnej schopnosti modelov tréňovaných na takýchto dátach čo vedie k neoptimálnym výsledkom. Hlavným prínosom práce je prehľadné rozdelenie existujúcich metód, ktoré sa používajú na znižovanie vplyvu šumu v označeniach ako napríklad robustné statové funkcie, regularizáciu, úpravu alebo preváhovanie dát pri vysokej losse a výber a oprava problemových vzoriek.

# Kapitola 3

## Dáta

V tejto kapitole opíšem formát poskytnutých dát, opíšem ake dáta to sú a ako som ich spracoval, potom sa pozrieme na anotácie a ich distribúciu a na záver spomeniem jeden problém, ktorý sme s datasetom mali.

K datasetu boli poskytnuté masky meniskov, samotné skeny a tabuľka s informačnými anotáciami.

### 3.1 Formát dát

Poskytnuté nam boli anonymizované dáta, zbierane Petrom Bluskom v spolupraci s nemocnicnou sieťou Agel. K dispozícii nam bolo poskytnutých XXXX 3D snimkov kolena z MRI prístrojov, ktorých weight proton time je XXXX. K datasetu boli poskytnuté taktiez maskami meniskov, ktoré sme neskôr použili na odstránenie bakerovej cysty, a taktiez samozrejme anotácie k datam.

Samotné data nam boli poskytnuté ako priecinky buď pre 3 roviny, ktorých názov je anonymizované ID pacienta a v tých priecinkoch je samotný sken v danej rovine uložený ako numpy array. Priecinok taktiez obsahuje json subor nazvaný patient info, v ktorom sa nachádza pohlavie, vek, výška a váha pacienta.

### 3.2 Anotácie, ich interpretácia a distribúcia

Anotácie nam boli poskytnuté v samostatnom csv subore, ktorý pozostával z dát indexovaných podľa anonymizovaného ID pacienta a stĺpcov, v ktorých sa nachádza mnoho diagnóz pre dané koleno. Nas zaujímali tieto stĺpce:

- `knee_joint_effusion.none`,
- `knee_joint_effusion.minimal`,
- `knee_joint_effusion.mild`,

- `knee_joint_effusion.moderate`,
- `knee_joint_effusion.severe`.

Tieto stĺpce reprezentujú závažnosť zmnoženia vody v kolene, ktorá je opisovaná v časti ???. Z daných stĺpcov môže byť true maximálne jeden.

Distribúcia týchto anotácií je opísaná na obrázku 3.1. Vidíme, že distribúcia nie je jednotná, hlavný problém je pri severe clase, kde by sme mohli mať problém s malým množstvom vzoriek.

Obr. 3.1: Distribúcia anotácií podľa závažnosti zmnoženia vody v kolene. Počty tried: none – 425, minimal – 247, mild – 589, moderate – 467, severe – 96.

| Trieda   | Počet vzoriek |
|----------|---------------|
| none     | 425           |
| minimal  | 247           |
| mild     | 589           |
| moderate | 467           |
| severe   | 96            |

Tabuľka 3.1: Počet vzoriek pre jednotlivé triedy anotácií.

### 3.3 Problém s otočením

Pri práci s datasetom sme narazili na problém jednotnej štandardizácie snímok, konkrétne sme narazili na problém, že pri niektorých snímkach, začínal snímok od jablčka a nie od zadného kolena, ako je opísané na obrázku 3.2. Neskôr sme tento problém identifikovali ako chybu u technických pracovníkoch obsluhujúcich dané MRI, konkrétne pri pracoviskách, ktoré mali v názve anonymizovaného ID pacienta buď MSK alebo JOINTS KNEE. Týchto snímok v datasete bolo okolo XXX.

Obr. 3.2: Porovnanie snímky kolena so správnym a nesprávnym smerovaním.

# Kapitola 4

## Implementácia

### 4.1 Preprocessing

### 4.2 Tréning

### 4.3 Problémy





# Kapitola 5

## Improvements

### 5.1 Ordinal Regression

### 5.2 Dataset cleanup

#### 5.2.1 Použitie intenzít

#### 5.2.2 Detekcia outlierov pomocou modelu

### 5.3 Label smoothing



# Kapitola 6

## Jadro a členenie práce

V tejto kapitole si povieme niečo o jadre práce a o jej členení. V zdrojovom kóde v súbore `kapitola.tex` nájdete ukážky použitých príkazov LaTeXu potrebných na písanie nadpisov a podnadpisov a číslovaných a nečíslovaných zoznamov.

Text podkapitoly 6.1 je prebratý zo smernice o záverečných prácach [10, článok 5] a popisuje typické členenie jadra práce (text medzi kapitolami Úvod a Záver). Hoci v niektorých študijných odboroch je vyžadované členenie práce na kapitoly uvedené v smernici, v informatike nie je nutné toto členenie dodržiavať a môžete text rozdeliť do kapitol podľa potrieb konkrétnej témy. Aj tak je však potrebné uviesť súčasný stav problematiky a z práce musí byť tiež jasný váš celkový prínos ako aj detaily vašej práce. Tu uvedené podkapitoly sú len na ukážku použitia príslušných príkazov v LaTeXu, vo vašej práci by ste mali spravidla nemali mať podkapitoly s textom iba na pár riadkov a mali by ste sa tiež vyvarovať prílišnému používaniu odrážkových alebo číslovaných zoznamov.

### 6.1 Jadro práce podľa smernice

Jadro je hlavná časť školského diela a člení sa na kapitoly, podkapitoly, odseky a pod., ktoré sa vzostupne číslujú. Členenie jadra školského diela je určené typom školského diela. Vo vedeckých a odborných prácach má jadro spravidla tieto hlavné časti:

- súčasný stav riešenej problematiky doma a v zahraničí,
- cieľ práce,
- metodika práce a metódy skúmania,
- výsledky práce,
- diskusia.

### 6.1.1 Súčasný stav

V časti súčasný stav riešenej problematiky doma a v zahraničí autor uvádza dostupné informácie a poznatky týkajúce sa danej témy. Zdrojom pre spracovanie sú aktuálne publikované práce domácich a zahraničných autorov. Podiel tejto časti práce má tvoriť približne 30 % práce.

### 6.1.2 Cieľ práce

Časť cieľ práce školského diela jasne, výstižne a presne charakterizuje predmet riešenia. Súčasťou sú aj rozpracované čiastkové ciele, ktoré podmieňujú dosiahnutie cieľa hlavného.

### 6.1.3 Metodika práce a metódy skúmania

Časť metodika práce a metódy skúmania spravidla obsahuje:

1. charakteristiku objektu skúmania,
2. pracovné postupy,
3. spôsob získavania údajov a ich zdroje,
4. použité metódy vyhodnotenia a interpretácie výsledkov,
5. štatistické metódy.

### 6.1.4 Výsledky práce a diskusia

Časti výsledky práce a diskusia sú najvýznamnejšími časťami školského diela. Výsledky (vlastné postoje alebo vlastné riešenia), ku ktorým autor dospel, sa musia logicky usporiadať a pri opisovaní sa musia dostatočne zhodnotiť. Zároveň sa komentujú všetky skutočnosti a poznatky v konfrontácii s výsledkami iných autorov. Výsledky práce a diskusia môžu tvoriť aj jednu samostatnú časť a spoločne tvoria spravidla 30 až 40 % školského diela.

# Kapitola 7

## Ukážky užitočných príkazov v systéme LaTeX

V tejto kapitole si ukážeme príklady niektorých užitočných príkazov, ako napríklad správne používanie tabuliek a obrázkov, číslovanie matematických výrazov a podobne. Konkrétne príkazy použité v tejto kapitole nájdete v zdrojovom súbore `latex.tex`. Všimnite si, že pre potreby obsahu a hlavičky stránky je v zdrojovom súbore uvedený aj skrátený názov tejto kapitoly. Ďalšie užitočné príkazy nájdete aj v kapitole 6, na ktorú sme sa na tomto mieste odvolali príkazom `\ref`.

### 7.1 Obrázky


Vašu prácu ilustrujte vhodnými obrázkami. Pri použití programu `pdflatex` je potrebné pripraviť obrázky vo formáte `pdf`, `jpg` alebo `png`. Vektorové obrázky (napr. `eps`, `svg`) je najvhodnejšie skonvertovať do formátu `pdf`, napríklad programom `Inkscape`. Na vkladanie obrázkov použite prostredie `figure`, ktoré obrázok umiestni na vhodné miesto, väčšinou na vrch alebo spodok stránky a tiež sa stará o automatické číslovanie obrázkov. Na každý obrázok sa treba v hlavnom texte odvolať. Napríklad ilustráciu hry Červík vidíme na obrázku 7.1. Pri odvolávaní sa na číslo obrázku používame príkaz `\ref`. Pri vložení alebo zmazaní obrázku tak nemusíme ručne všetky ostatné obrázky prečíslovať.

Podobne tabuľky vkladajte pomocou prostredia `table`, pričom samotnú tabuľku vytvoríte príkazom `tabular`. Každú tabuľku potom spomeňte aj v hlavnom texte. Napríklad v tabuľke 7.1 vidíme porovnanie časov niekoľkých fiktívnych programov.

V texte môžete tiež potrebovať dlhšie matematické výrazy, ako napríklad tento

$$\sum_{k=0}^n q^k = \frac{q^{n+1} - 1}{q - 1}. \quad (7.1)$$

Použitím prostredia `equation` bol tento výraz zarovnaný na stred na zvláštnom



Obr. 7.1: Ukážka hry Červík. Červík je znázornený červenou farbou, voľné políčka sivou, jedlo zelenou a steny čiernou. Hoci tento popis obrázku je dlhší, v zdrojovom texte je aj kratšia verzia, ktorá sa zobrazí v zozname obrázkov.

Tabuľka 7.1: Doba výpočtu a operačná pamäť potrebná na spracovanie vstupu XYZ. V tomto popise môžeme vysvetliť detaily potrebné pre pochopenie údajov v tabuľke.

| Meno programu     | Čas (s) | Pamäť (MB) |
|-------------------|---------|------------|
| Môj super program | 25.6    | 120        |
| Speedy 3.1        | 32.1    | 100        |
| VeryOld           | 244.1   | 200        |

riadku a očíslovaný. Na toto číslo sa tiež môžeme odvolať príkazom `\ref`. Napríklad rovnica (7.1) predstavuje súčet geometrickej postupnosti.

V práci tiež možno budete uvádzať úryvky kódu v niektorom programovacom jazyku.

Môže vám pomôcť prostredie `lstlisting` z balíčka `listings`, v ktorom môžete nastaviť aj jazyk a kód bude krajšie sformátovaný. Ukážku nájdete ako Algoritmus

7.1.

Napokon, v texte nezabudnite citovať použitú literatúru pomocou príkazu `\cite`. Napríklad ďalšie detaily o systéme LaTeX nájdete v knihe od Tobiasa Oetikera a kolektívu [7]. Pre ukážku citujeme aj článok z vedeckého časopisu [3] a článok z konferencie [2], technickú správu [4], knihu [1] a materiál z internetu [10].

Algoritmus 7.1: Algoritmus na výpočet faktoriálu v jazyku C

---

```

int factorial = 1;
for(int i = 1; i <= n; i++) {
    factorial *= i;
}

```

---

# Záver

Na záver už len odporúčania k samotnej kapitole Záver v bakalárskej práci podľa smernice [10]: „V závere je potrebné v stručnosti zhrnúť dosiahnuté výsledky vo vzťahu k stanoveným cieľom. Rozsah záveru je minimálne dve strany. Záver ako kapitola sa nečísluje.“

Všimnite si správne písanie slovenských úvodzoviek okolo predchádzajúceho citátu, ktoré sme dosiahli príkazom \uv.

V informatických prácach niekedy býva záver kratší ako dve strany, ale stále by to mal byť rozumne dlhý text, v rozsahu aspoň jednej strany. Okrem dosiahnutých cieľov sa zvyknú rozoberať aj otvorené problémy a námety na ďalšiu prácu v oblasti. Abstrakt, úvod a záver práce obsahujú podobné informácie. Abstrakt je kratší text, ktorý má pomôcť čitateľovi sa rozhodnúť, či vôbec prácu chce čítať. Úvod má umožniť zorientovať sa v práci skôr než ju začne čítať a záver sumarizuje najdôležitejšie veci po tom, ako prácu prečítal, môže sa teda viac zamerať na detaily a využívať pojmy zavedené v práci.





# Literatúra

- [1] X. Autor1 and Y. Autor2. *Názov knihy*. Vydavateľstvo, 1900.
- [2] X. Autor1 and Y. Autor2. Názov článku (väčšinou z konferencie). In *Názov zborníka (väčšinou názov konferencie spolu s ročníkom)*, pages 1–100. Vydavateľstvo, 1900.
- [3] X. Autor1 and Y. Autor2. Názov článku z časopisu. *Názov časopisu, ktorý článok uverejnil*, 4(3):1–100, 1900.
- [4] X. Autor1 and Y. Autor2. Názov technickej správy. Technical Report TR123/1999, Inštitút vydávajúci správu, June 1999.
- [5] Davood Karimi, Haoran Dou, Simon K. Warfield, and Ali Gholipour. Deep learning with noisy labels: Exploring techniques and remedies in medical image analysis. *Medical Image Analysis*, 65:101759, 2020. [Citované 2026-05-18] Dostupné z <https://pmc.ncbi.nlm.nih.gov/articles/PMC7484266/>.
- [6] Omar S. M. El Nahhas, Chiara M. L. Loeffler, Zunamys I. Carrero, Marko van Treeck, Fiona R. Kolbinger, Katherine J. Hewitt, Hannah S. Muti, Mara Graziani, Qinghe Zeng, Julien Calderaro, Nadina Ortiz-Brüchle, Tanwei Yuan, Michael Hoffmeister, Hermann Brenner, Alexander Brobeil, Jorge S. Reis-Filho, and Jakob Nikolas Kather. Regression-based Deep-Learning predicts molecular biomarkers from pathology slides. *Nature Communications*, 15:1253, 2024. [Citované 2026-05-18] Dostupné z <https://www.nature.com/articles/s41467-024-45589-1>.
- [7] Tobias Oetiker, Hubert Partl, Irene Hyna, and Elisabeth Schlegl. *Nie príliš stručný úvod do systému LaTeX2ε*. 2002. Preklad Ján Buša ml. a st.
- [8] Sandhya Raman, Garry E. Gold, Matthew S. Rosen, and Bragi Sveinsson. Automatic estimation of knee effusion from limited MRI data. *Scientific Reports*, 12(1):3155, 2022. [Citované 2026-05-18] Dostupné z <https://rdcu.be/fGFe5>.
- [9] Jialin Shi, Kailai Zhang, Chenyi Guo, Youquan Yang, Yali Xu, and Ji Wu. A survey of label-noise deep learning for medical image analysis. *Medical Image*

*Analysis*, 95:103166, 2024. [Citované 2026-05-18] Dostupné z <https://www.sciencedirect.com/science/article/pii/S1361841524000914>.

- [10] Univerzita Komenského v Bratislave. Vnútorňý predpis č. 7/2018, Úplné znenie vnútorného predpisu č. 12/2013 Smernice rektora Univerzity Komenského v Bratislave o základných náležitostiach záverečných prác, rigorózných prác a habilitačných prác, kontrole ich originality, uchovávaní a sprístupňovaní na Univerzite Komenského v Bratislave v znení dodatku č. 1 a dodatku č. 2 smernica rektora Univerzity Komenského v Bratislave o základných náležitostiach záverečných prác, rigorózných prác a habilitačných prác, kontrole ich originality, uchovávaní a sprístupňovaní na Univerzite Komenského v Bratislave, 2013. [Citované 2020-10-19] Dostupné z [https://uniba.sk/fileadmin/ruk/legislativa/2018/Vp\\_2018\\_07.pdf](https://uniba.sk/fileadmin/ruk/legislativa/2018/Vp_2018_07.pdf).
- [11] Yishu Wei, Yu Deng, Cong Sun, Mingquan Lin, Hongmei Jiang, and Yifan Peng. Deep learning with noisy labels in medical prediction problems: a scoping review. *Journal of the American Medical Informatics Association*, 31(7):1596–1607, 2024. [Citované 2026-05-18] Dostupné z <https://academic.oup.com/jamia/article/31/7/1596/7685298>.
- [12] Hyeyeon Won, Hye Sang Lee, Daemyung Youn, Doohyun Park, Taejoon Eo, Wooju Kim, and Dosik Hwang. Deep Learning-Based joint effusion classification in adult knee radiographs: A Multi-Center prospective study. *Diagnostics*, 14(17):1900, 2024. [Citované 2026-05-18] Dostupné z <https://www.mdpi.com/2075-4418/14/17/1900>.

# Príloha A: obsah elektronickej prílohy

V elektronickej prílohe priloženej k práci sa nachádza zdrojový kód programu a súbory s výsledkami experimentov. Zdrojový kód je zverejnený aj na stránke <http://mojadresa.com/>.

Ak uznáte za vhodné, môžete tu aj podrobnejšie rozpísať obsah tejto prílohy, prípadne poskytnúť návod na inštaláciu programu. Alternatívou je tieto informácie zahrnúť do samotnej prílohy, alebo ich uviesť na oboch miestach.



## Príloha B: Používateľská príručka

V tejto prílohe uvádzame používateľskú príručku k nášmu softvéru. Tu by ďalej pokračoval text príručky. V práci nie je potrebné uvádzať používateľskú príručku, pokiaľ je používanie softvéru intuitívne alebo ak výsledkom práce nie je ucelený softvér určený pre používateľov.

V prílohách môžete uviesť aj ďalšie materiály, ktoré by mohli pôsobiť rušivo v hlavnom texte, ako napríklad rozsiahle tabuľky a podobne. Materiály, ktoré sú príliš dlhé na ich tlač, odovzdajte len v electronickej prílohe.